



Microsoft Azure

Azure Foundry & Azure

OpenAI

配置手册

面向新客户的端到端配置指南
涵盖 AOAI 申请开通、Foundry 配置、模型部署

版本 1.0 — 2026 年 4 月

目录

1. 概述：Azure Foundry 与 Azure OpenAI
2. 前提条件与准备工作
3. 申请开通 Azure OpenAI 服务
4. 创建 Azure Foundry 资源
5. 部署 OpenAI 模型（GPT-4.1 / GPT-5.5 / GPT-Image-2 等）
6. 认证与访问控制（API Key / Entra ID / Managed Identity）
7. 快速验证：调用 API
8. 配额与限制（Quota / Tier）
9. 常见问题排查（FAQ）
10. 附录：可用模型与区域一览

1. 概述：Azure Foundry 与 Azure OpenAI

Azure AI Foundry（原 Azure AI Studio）是微软统一的 AI 开发平台，集成了 Azure OpenAI、开源模型目录、AI 搜索、评估工具等能力，为企业提供一站式 AI 开发与部署体验。

Azure OpenAI Service (AOAI) 是 Azure 上的托管 OpenAI 服务，提供 GPT-4o、GPT-4.1、GPT-5.5、GPT-Image-2、DALL·E、Whisper 等模型，兼具企业级安全、合规与可扩展性。

核心优势

特性	说明
企业安全	数据不会用于训练模型；支持 VNet、Private Endpoint、CMK 加密
合规认证	SOC 2、ISO 27001、HIPAA、GDPR 等
全球部署	30+ 区域可用，支持就近部署降低延迟
统一计费	通过 Azure 订阅统一管理，支持 EA / CSP / PAYG
内容安全	内置 Content Safety 过滤，可自定义策略

2. 前提条件与准备工作

在开始之前，请确认以下条件已满足：

1. **Azure** 订阅 — 需要一个有效的 Azure 订阅（PAYG / EA / CSP 均可）
2. **Azure** 账户 — 拥有订阅的 Contributor 或 Owner 权限
3. **AOAI** 访问权限 — Azure OpenAI 需要申请开通（见第 3 章）
4. 浏览器 — 推荐使用 Edge 或 Chrome 访问 Azure Portal

 提示：如果您是 CSP 客户，请联系您的 CSP 合作伙伴协助开通订阅和 AOAI 权限。EA 客户可通过 EA Portal 管理订阅。

3. 申请开通 Azure OpenAI 服务

Azure OpenAI 目前需要通过申请审批才能使用。以下是申请流程：

3.1 申请入口

- 1 访问申请页面：<https://aka.ms/oai/access>
- 2 使用您的企业 **Azure AD** 账户（工作或学校账户）登录
- 3 填写申请表单

3.2 申请表单关键字段

字段	说明	建议
Subscription ID	要开通 AOAI 的订阅 ID	在 Azure Portal → Subscriptions 中获取
Company Name	公司名称	填写正式注册名称
Use Case Description	使用场景描述	详细描述业务场景，提高审批通过率
Expected Models	计划使用的模型	选择 GPT-4 / GPT-4o / DALL·E 等
Responsible AI Contact	负责人邮箱	确保为有效的企业邮箱

 注意：个人账户（@outlook.com / @hotmail.com）通常无法通过审批。请使用企业 Azure AD 账户申请。审批通常需要 1-5 个工作日。

3.3 审批状态检查

审批通过后，您会收到邮件通知。也可在 Azure Portal 中尝试创建 Azure OpenAI 资源来确认权限是否已开通。



加速审批技巧：

- 使用场景描述要具体、详细（如“智能客服”、“文档摘要”等）
- 说明数据处理合规要求（如 GDPR、数据不出境等）

- 提供公司官网链接
- 如有微软客户经理（TAM/CSA），可请其协助加速

4. 创建 Azure Foundry 资源

4.1 通过 Azure Portal 创建

- 1 登录 `https://portal.azure.com`
- 2 搜索 "Azure AI Foundry" (或 "Azure OpenAI")
- 3 点击 "+ Create"
- 4 填写基本信息：

配置项	说明
Subscription	选择已开通 AOAI 的订阅
Resource Group	选择已有或新建资源组
Region	推荐 East US 2 、 Sweden Central 、 West US 3 (模型可用性最全)
Name	全局唯一名称，如 <code>mycompany-aoai-prod</code>
Pricing Tier	选择 Standard S0

- 5 **Network** 选项卡：选择网络访问方式
 - **All networks** — 公网可访问 (开发测试用)
 - **Selected networks** — 指定 IP / VNet (推荐生产环境)
 - **Disabled** — 仅 Private Endpoint 访问 (最高安全级别)
- 6 点击 "Review + Create" → "Create"

4.2 通过 **Azure CLI** 创建

```
# 登录
az login

# 创建资源组
az group create --name rg-aoai-prod --location eastus2

# 创建 Azure OpenAI 资源
az cognitiveservices account create \
  --name mycompany-aoai-prod \
  --resource-group rg-aoai-prod \
  --kind OpenAI \
  --sku S0 \
  --location eastus2
```

5. 部署 OpenAI 模型

资源创建完成后，需要为每个模型创建部署（**Deployment**）。

5.1 通过 **Azure AI Foundry Portal** 部署

- 1 访问 `https://ai.azure.com`
- 2 选择您的 Foundry 资源/项目
- 3 左侧菜单 → **"Model catalog" 或 "Deployments"**
- 4 点击 **"+ Deploy model"**
- 5 选择模型并配置部署参数

5.2 主要可用模型

模型	部署名称示例	类型	用途
GPT-4.1	<code>gpt-4.1</code>	Chat	高性能对话与推理
GPT-4.1 mini	<code>gpt-4.1-mini</code>	Chat	性价比优选
GPT-4.1 nano	<code>gpt-4.1-nano</code>	Chat	低延迟轻量任务
GPT-4o	<code>gpt-4o</code>	Chat (多模态)	文本 + 图片理解
GPT-5.5	<code>gpt-5.5</code>	Chat	最新一代旗舰模型
GPT-Image-2	<code>gpt-image-2</code>	Image	图像生成与编辑
o4-mini	<code>o4-mini</code>	Reasoning	推理任务（数学/代码）
text-embedding-3-large	<code>text-embedding-3-large</code>	Embedding	文本向量化
Whisper	<code>whisper</code>	Speech	语音转文字

TTS / TTS-HD	tts	Speech	文字转语音
--------------	-----	--------	-------

5.3 部署配置参数

参数	说明	建议
Deployment name	API 调用时使用的名称	与模型名保持一致，如 <code>gpt-4.1</code>
Model version	模型版本号	选择最新稳定版
Deployment type	Standard / Provisioned / Global	Standard（按需）适合起步
TPM (Tokens Per Minute)	每分钟 Token 配额	根据业务量设置，可后续调整

 部署类型说明：

- **Standard** — 按需计费，共享容量，适合开发和中低流量场景
- **Provisioned (PTU)** — 预留吞吐量，固定月费，适合高流量生产环境
- **Global Standard** — 跨区域动态路由，更高可用性

5.4 通过 CLI 部署模型

```
# 部署 GPT-4.1
az cognitiveservices account deployment create \
  --name mycompany-aoai-prod \
  --resource-group rg-aoai-prod \
  --deployment-name gpt-4.1 \
  --model-name gpt-4.1 \
  --model-version "2025-04-14" \
  --model-format OpenAI \
  --sku-capacity 80 \
  --sku-name Standard

# 部署 GPT-Image-2
az cognitiveservices account deployment create \
  --name mycompany-aoai-prod \
  --resource-group rg-aoai-prod \
  --deployment-name gpt-image-2 \
```

```
--model-name gpt-image-2 \  
--model-version "2025-04-15" \  
--model-format OpenAI \  
--sku-capacity 10 \  
--sku-name Standard
```

6. 认证与访问控制

Azure OpenAI 支持三种认证方式：

6.1 API Key 认证（最简单）

- 1 Azure Portal → 您的 OpenAI 资源 → **"Keys and Endpoint"**
- 2 复制 **KEY 1** 或 **KEY 2** 和 **Endpoint**

```
# 使用 API Key
curl https://mycompany-aoai-prod.openai.azure.com/openai/deployments/
gpt-4.1/chat/completions?api-version=2024-12-01-preview \
  -H "Content-Type: application/json" \
  -H "api-key: YOUR_API_KEY" \
  -d '{"messages":[{"role":"user","content":"Hello"}]}'
```

6.2 Microsoft Entra ID（推荐生产环境）

使用 Azure AD Token 认证，更安全，支持 RBAC 精细权限控制。

IAM 角色	权限
Cognitive Services OpenAI User	调用 API（Chat / Image / Embedding 等） 
Cognitive Services OpenAI Contributor	调用 API + 管理部署
Cognitive Services Contributor	管理资源配置（不含数据面）

 常见误区：Contributor 角色不能调用 API！需要专门的 **Cognitive Services OpenAI User** 角色。

6.3 Managed Identity（VM / App Service 场景）

适用于 Azure VM、App Service、AKS 等运行环境，无需管理密钥。

```
# Python 示例
from azure.identity import DefaultAzureCredential
```

```
from openai import AzureOpenAI

client = AzureOpenAI(
    azure_endpoint="https://mycompany-aoai-prod.openai.azure.com/",
    azure_ad_token_provider=DefaultAzureCredential(),
    api_version="2024-12-01-preview"
)

response = client.chat.completions.create(
    model="gpt-4.1",
    messages=[{"role": "user", "content": "你好"}]
)
```

7. 快速验证：调用 API

7.1 Chat Completion (GPT-4.1 / GPT-5.5)

```
import openai

client = openai.AzureOpenAI(
    azure_endpoint="https://mycompany-aoai-prod.openai.azure.com/",
    api_key="YOUR_API_KEY",
    api_version="2024-12-01-preview"
)

# 对话
response = client.chat.completions.create(
    model="gpt-5.5", # 部署名称
    messages=[
        {"role": "system", "content": "你是一个有帮助的助手。"},
        {"role": "user", "content": "请介绍 Azure AI Foundry 的核心功能。"}
    ],
    temperature=0.7,
    max_tokens=1000
)
print(response.choices[0].message.content)
```

7.2 Image Generation (GPT-Image-2)

```
# 图像生成
response = client.images.generate(
    model="gpt-image-2", # 部署名称
    prompt="一只穿着宇航服的猫在月球上散步，赛博朋克风格",
    n=1,
    size="1024x1024",
    quality="high"
)
print(response.data[0].url)
```

7.3 Embedding (文本向量化)

```
response = client.embeddings.create(
    model="text-embedding-3-large",
```

```
input="Azure AI Foundry 是微软的统一 AI 平台"  
)  
print(f"向量维度: {len(response.data[0].embedding)}")
```

7.4 在 **AI Foundry Playground** 测试

如果不想写代码，可以直接在 <https://ai.azure.com> 的 **Playground** 中测试模型：

1. 选择已部署的模型
2. 在 Chat Playground 输入提示词
3. 调整参数（Temperature、Max Tokens 等）
4. 查看响应结果

8. 配额与限制

8.1 默认配额

模型	默认 TPM	默认 RPM	可申请提升
GPT-4.1	80K	480	✓
GPT-4o	150K	900	✓
GPT-5.5	80K	480	✓
GPT-Image-2	—	10 images/min	✓
text-embedding-3-large	350K	2100	✓

TPM = Tokens Per Minute , RPM = Requests Per Minute

8.2 提升配额

- 1 Azure Portal → 您的 OpenAI 资源 → **"Quotas"**
- 2 选择要提升的模型/部署
- 3 点击 **"Request Quota Increase"**
- 4 或提交支持工单：Azure Portal → **"Help + support"** → **"New support request"**

8.3 Tier 等级

新订阅默认为 **Tier 1**，随使用量和付费历史自动升级：

Tier	解锁条件	配额倍数
Tier 1	默认	1x
Tier 2	累计消费 \$500+	2x
Tier 3	累计消费 \$2,000+	4x

Tier 4-6	更高消费 / 企业协议	8x-32x
----------	-------------	--------

9. 常见问题排查

问题	原因	解决方案
创建资源时找不到 OpenAI 选项	订阅未开通 AOAI	提交申请表： aka.ms/oai/access
部署模型时提示区域不可用	所选区域不支持该模型	更换区域（推荐 East US 2 / Sweden Central）
API 返回 401 Unauthorized	API Key 错误或 IAM 角色不足	检查 Key / 确认分配了 Cognitive Services OpenAI User 角色
API 返回 429 Too Many Requests	超出 TPM/RPM 配额	降低请求频率或申请提升配额
API 返回 404 Not Found	部署名称错误或 API 版本不对	确认 deployment name 和 api-version 参数
Content Filter 拒绝请求	内容安全过滤触发	调整 prompt 或自定义 Content Filter 策略
Managed Identity 返回 401	IAM 角色传播延迟	等待 5-10 分钟后重试
GPT-Image-2 返回空结果	区域不支持或配额为 0	确认区域支持且已分配图像配额

10. 附录：推荐区域与模型可用性

10.1 推荐区域（模型覆盖最全）

区域	GPT-4.1	GPT-4o	GPT-5.5	GPT-Image-2	Embedding
East US 2	✓	✓	✓	✓	✓
Sweden Central	✓	✓	✓	✓	✓
West US 3	✓	✓	✓	✓	✓
Japan East	✓	✓	—	—	✓
UK South	✓	✓	—	✓	✓

💡 选区建议：如果需要最全模型支持，优先选择 **East US 2** 或 **Sweden Central**。如需中国大陆低延迟，可考虑 **Japan East**（部分模型）。

10.2 重要链接

资源	链接
Azure AI Foundry	https://ai.azure.com
Azure Portal	https://portal.azure.com
AOAI 申请	https://aka.ms/oai/access
定价信息	https://azure.microsoft.com/pricing/details/cognitive-services/openai-service/
模型可用性	https://learn.microsoft.com/azure/ai-services/openai/concepts/models
API 文档	https://learn.microsoft.com/azure/ai-services/openai/reference
配额与限制	https://learn.microsoft.com/azure/ai-services/openai/quotas-limits

Azure Foundry & Azure OpenAI 配置手册 v1.0 — 2026 年 4 月
如有疑问，请联系您的微软客户经理或提交 Azure 支持工单